구매 패턴 기반 고객 페르소나 도출과 채널 오분류 고객 마케팅 전략

김정우, 안재원

목차

01	데이터 소개 · 품질 점검	데이터 구조·출처, 결측·중복·이상치·하한 절단값 점검
02	EDA · 전처리	구매액 분포, 채널별 차이, Yeo-Johnson 변환, PCA
03	군집분석	시드 안정성 기준 k=4, 고객 페르소나 4종
04	채널 예측 모델	5개 모델 비교, RandomForest 채택, 변수 중요도
05	오분류 고객 분석	Test 채널 오분류 4명과 신뢰도 기준 2가지 유형
06	마케팅 전략	전략 원칙과 유형별(A-1·A-2·B·C) 핵심 액션
07	한계 및 결론	표본·군집·데이터 한계, 향후 과제와 결론

01

데이터 소개 · 품질 점검

1 데이터 소개

2 데이터 품질 점검

3 하한 절단값 점검

01

데이터 소개

도매업체 고객 440명, 결측·중복 0건, 고객의 3분의 2가 Horeca 채널

변수	의미	역할
Channel	1=Horeca, 2=Retail	종속변수
Fresh	신선식품 연간 구매액	독립변수
Milk	유제품 연간 구매액	독립변수
Grocery	식료품 연간 구매액	독립변수
Frozen	냉동식품 연간 구매액	독립변수
Detergents_Paper	세제/종이류 연간 구매액	독립변수
Delicassen	즉석/가공식품 연간 구매액	독립변수
Region	고객 지역 (1=Lisbon, 2=Oporto, 3=Other)	독립변수

출처: Cardoso, M. (2013), Wholesale customers (Kaggle)

채널 구성



67.7%
Horeca
호텔/레스토랑/카페 · 298명

32.3%
Retail
소매유통 · 142명

데이터 한계

- 수집 기간과 화폐 단위가 불명확
- 따라서 실제 마케팅 의사결정이 아니라 **오분류 고객 식별·대응 방법론 검증**을 목적으로 설계한다.

01

데이터 품질 점검

결측치

0건

통과

440행 × 8열 전체에서 결측 없음

조치
그대로 사용

중복 행

0건

통과

동일 고객 중복 기록 없음

조치
440행 전부 분석에 사용

상한 이상치

4.5~9.8%

변환 필요

IQR 기준 전체 108행(24.6%), 행 삭제 없이 유지

조치
모델링 전 로그변환 or Yeo-Johnson 변환으로 분포 완화

Region 변수 (제거)

p = 0.114

변수 제외

독립성 검정(카이제곱 검정) Channel과 연관이 있다고 볼 근거 없음

조치
분석 변수에서 제외한다

결과

1. 440행을 삭제·보정 없이 모두 쓰고, 6개 구매액 변수는 변환하고 Region은 제외한다.
2. 이상치는 하한 절단값(3)을 주의하여 로그변환과 Yeo-Johnson변환을 비교해 택한다.

01

하한 절단값 점검

4개 변수의 최솟값이 모두 3으로 같아, 하한 절단값일 가능성을 둔다

변수별 최솟값과 그다음 작은 값

변수	최솟값	3 다음 최솟값	값이 3인 개수
Fresh	3	9	2개
Grocery	3	137	1개
Detergents_Paper	3	5	2개
Delicassen	3	7	4개
Milk	55	-	0개
Frozen	25	-	0개

하한 절단값으로 의심한 이유

- **6개 중 4개 변수**의 최솟값이 똑같이 3이다.
- Grocery는 3 다음 값이 **137**로, 3만 동떨어져 있다.
- Detergents_Paper는 다음 값이 5라 3이 실제 값일 수도 있지만, 공통 최솟값을 보면 **단정할 수 없다.**
- 판단 : 오류로 지우지 않고 유지하되, **하한 왜곡**에 주의해 변환 방법을 고른다.
- 추후 전처리에서 **로그 변환과 Yeo-Johnson 변환**을 비교해 하한 왜곡이 적은 방법을 택한다.

02

EDA · 모델링 전처리

1. 구매액 분포와 이상치
2. 채널별 품목 차이
3. Yeo-Johnson 변환
4. PCA 차원 축소

02

구매액 분포(단변량)

6개 구매액 변수 모두 오른쪽 꼬리가 길어, 모델링 전 변환이 필요하다

평균 > 중앙값

6개 변수 전부

소수의 대량 구매 고객이 평균을 끌어올림

2.5~11

왜도 (Skewness)

정규분포 기준 0에서 크게 벗어남

4.5~9.8%

변수당 상한 이상치 비율

IQR 기준 상한 이상치

시사점

분포 왜곡

로그 / Yeo-Johnson 변환으로 왜도를 줄인 뒤 거리 기반 군집과 분류 모형에 투입

품목 간 다중공선성

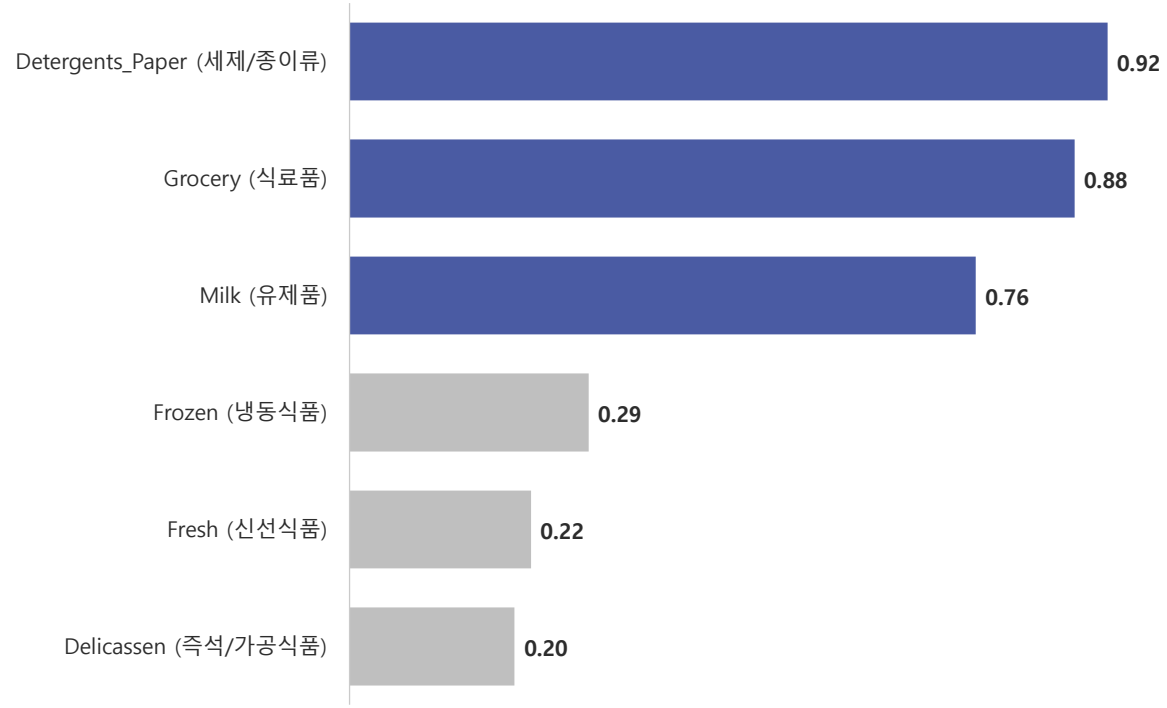
Milk · Grocery · Detergents_Paper(Retail 품목군) 간 Spearman 상관 **0.68~0.80 → PCA로 차원 축소**

02

채널별 품목 차이(이변량)

채널을 가르는 품목은 Retail 품목 3개(세제/종이류·식료품·유제품)다

채널 간 구매액 차이의 판별력, |Rank-Biserial|



Mann-Whitney U 검정, 6개 변수 모두 $p<0.05$

구매 방향

- **Retail이 더 많이 구매:** Detergents_Paper, Grocery, Milk, Delicassen
- **Horeca가 더 많이 구매:** Frozen, Fresh

해석

- 판별력 0.76~0.92인 **Retail 품목 3개**가 채널 차이의 대부분을 설명
- Horeca 품목(Fresh, Frozen)은 판별력 0.22~0.29로 약함

02

변환 방법 선택

로그 변환은 Fresh·Delicassen을 과보정해, Yeo-Johnson 변환으로 대체했다

변수별 왜도 · 0에 가까울수록 대칭

변수	원본	로그 변환	Yeo-Johnson (채택)
Fresh	2.55	-1.62	-0.04
Milk	4.04	-0.23	0.00
Grocery	3.58	-0.74	0.03
Frozen	5.89	-0.36	0.00
Detergents_Paper	3.62	-0.27	-0.02
Delicassen	11.11	-1.17	0.10

음영: 로그 변환 후 왜도가 음수로 크게 넘어간(과보정) 변수

원본
6개 변수 모두 오른쪽 꼬리 (왜도 2.55~11.11)

로그 변환
대부분 개선되지만 Fresh·Delicassen은 음수로 과보정: 하한 절단값 3(6쪽) 영향

Yeo-Johnson
6개 모두 **±0.1 이내**로 대칭에 가까워져 채택

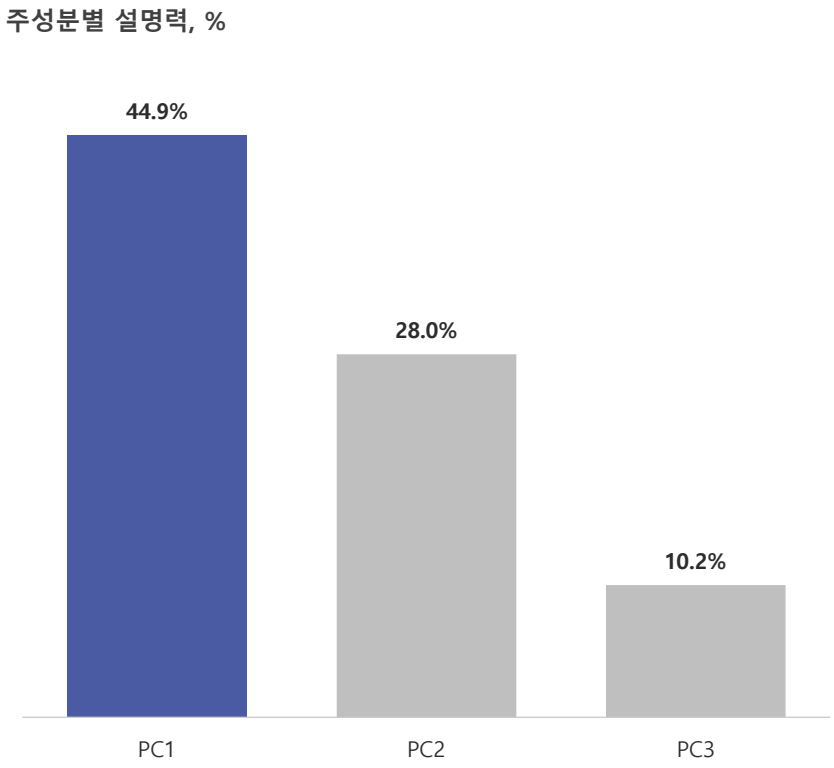
적용 원칙

- Yeo-Johnson은 0과 음수에도 적용되고 변수별 최적 λ를 추정해, 하한값에 민감한 로그 변환보다 안정적
- **데이터 누수 방지:** 채널예측 단계에서는 변환·PCA·군집화를 Train에만 fit한 뒤 Test에 적용

02

PCA 차원 축소

주성분 3개로 전체 분산의 83.1%를 설명한다



주성분	설명력	주요 구성 변수 (해석)
PC1	44.9%	Milk · Grocery · Detergents_Paper 식료품·유제품·세제/종이류 축
PC2	28.0%	Fresh · Frozen · Delicassen 신선·냉동·즉석식품 축
PC3	10.2%	Fresh(+) vs Delicassen(−) 신선식품 대 즉석식품 대비 축
누적	83.1%	3개 주성분으로 군집분석 수행

- PC1이 EDA에서 채널 판별력이 가장 컸던 **Retail 품목 3개**를 묶은 축으로, 전체 분산의 44.9%를 설명
- PC1만 쓰면 신선·냉동 축(PC2)과 신선 대 즉석식품 축(PC3) 정보가 빠지므로, 군집분석에는 **PC1~PC3을 함께 사용**

03

군집분석

1. k 선택: 시드 안정성
2. 고객 페르소나 4종
3. 페르소나별 채널 구성

03

군집 수(k) 선택

① 기존 지표

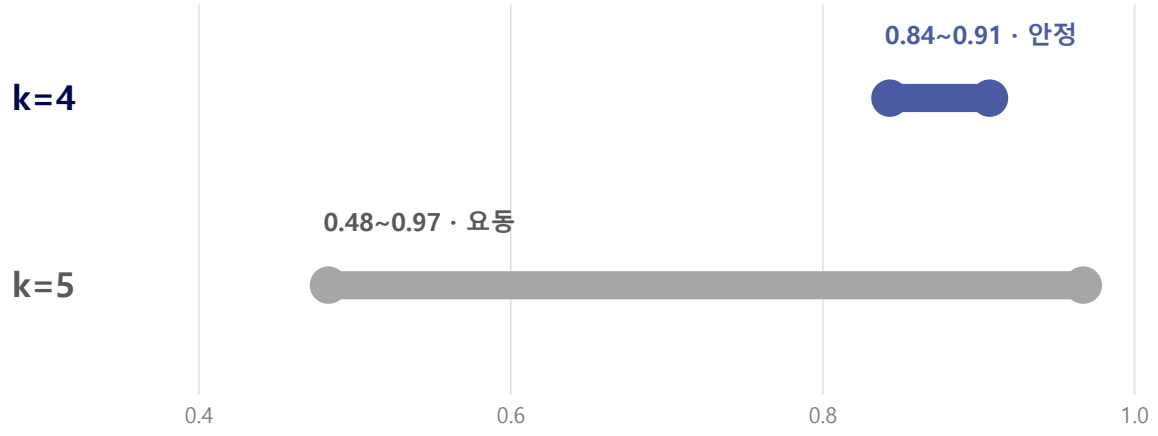
k	Elbow SSE	감소량	실루엣	균형지수
2	1,363.6	-	**0.358**	0.725
3	1,067.5	296.1	0.319	0.459
4	**906.8**	160.6	0.281	0.602
5	802.8	104.1	0.254	**0.804**
6	724.9	77.9	0.244	0.365

k=2 군집 × Channel 교차표 · 일치율 86.6%

k=2 군집	Horeca	Retail	합계
군집 0	248 (96.5%)	9	257
군집 1	50	133 (72.7%)	183

- 엘보우는 **k=4**, 실루엣은 **k=2**, 균형지수는 **k=5**를 가리킨다.
- k=2는 PC1 구조를 그대로 반영해 Channel을 복제할 위험이 있다 → 시드 안정성 **ARI로 최종 판단**

② 시드별 군집 결과 일치도(ARI)



ARI 1.0 = 시드가 달라도 군집 결과가 완전히 동일

균형지수: 실루엣 플롯에서 군집별 면적 중 가장 작은 군집의 상대 면적(최소상대면적). 1에 가까울수록 군집 크기가 고르게 나뉜다.

결론: 재현성 기준으로 **k=4** 최종 채택 (단, 실루엣 0.281로 군집 경계는 뚜렷하지 않음)

03

고객 페르소나 4종

C0
소량 신선식품 중심형

고객 수
181명 (41%)

총구매액 중앙값
17,415

주요 구매 비중

Fresh 50%	Milk 12%
Grocery 16%	Delicassen 5%
Frozen 14%	Det_Paper 3%

Horeca : Retail



98.3% : 1.7%

C1
중간 규모 식료품·유제품·세제/종이류 중심형

고객 수
78명 (18%)

총구매액 중앙값
26,498

주요 구매 비중

Grocery 40%	**Fresh 14%**
Milk 25%	Frozen 3%
Det_Paper 15%	Delicassen 3%

Horeca : Retail



42.3% : 57.7%

C2
대량 신선·냉동·즉석/가공식품 구매형

고객 수
81명 (18%)

총구매액 중앙값
43,394

주요 구매 비중

Fresh 53%	Milk 11%
Frozen 18%	Delicassen 6%
Grocery 11%	Det_Paper 2%

Horeca : Retail



91.4% : 8.6%

C3
대량 식료품·유제품·세제/종이류 구매형

고객 수
100명 (23%)

총구매액 중앙값
45,968

주요 구매 비중

Grocery 33%	**Det_Paper 14%**
Milk 23%	Delicassen 5%
Fresh 21%	Frozen 4%

Horeca : Retail



13.0% : 87.0%

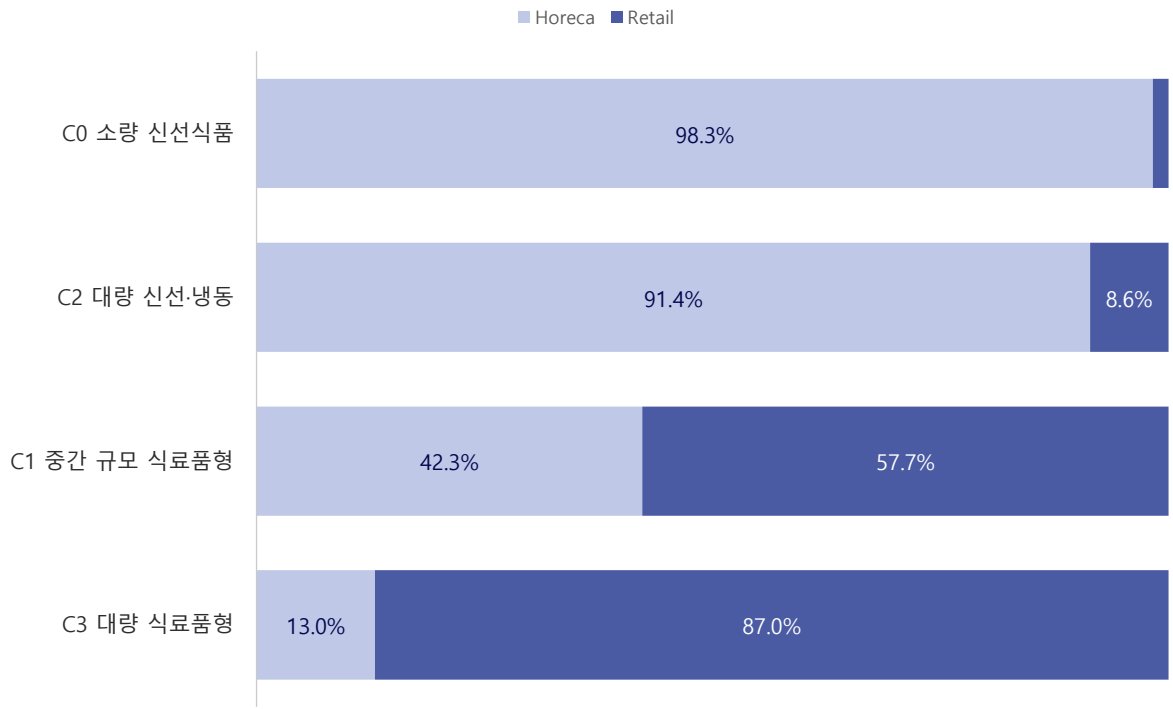
총구매액 단위는 원데이터 기준(화폐 단위 불명) · 주요 구매 비중은 군집별 품목 구매액 비중

03

페르소나별 채널 구성

구매 패턴만으로 채널이 대부분 설명되지만, C1은 두 채널이 섞여 오분류 위험이 가장 크다

페르소나별 채널 구성비, %



- **C0 · C2**는 Horeca가 90% 이상 → 신선·냉동 중심 구매가 Horeca의 전형
- **C3**는 Retail 87% → 식료품·유제품·세제/종이류 대량 구매가 Retail의 전형

주목할 군집

- **C1**은 Horeca 42.3% : Retail 57.7%로 섞여 있어, 구매 패턴만으로 채널을 가르기 가장 어려움
- → 분류모형 구축 전, **오분류가 발생할 가능성이 가장 큰 자리**로 미리 지목

04

채널 예측 모델

1. 5개 분류모형 비교
2. 변수 중요도

04

분류 모델 비교

5개 모델 모두 Macro F1 0.88~0.91로, 어떤 모델이든 구매 패턴만으로 채널이 약 90% 구분된다

Train 내부 StratifiedKFold 5-fold 교차검증 결과

모델	Accuracy	Macro F1 (mean±std)
RandomForest (채택)	0.918	0.906 ± 0.031
GradientBoosting	0.912	0.899 ± 0.049
SVM / KNN / LogisticRegression	0.89~0.90	0.88~0.89

모형 입력: Yeo-Johnson 6개 변수 + 군집 더미 · PCA는 군집 더미 생성에만 사용(주성분 미입력)

운영 근거 정확도

약 92%

교차검증 **Accuracy 0.918**

- 모델 간 차이가 작아(0.88~0.91), 우열보다 **구매 패턴만으로 채널이 구분된다**는 점이 핵심
- RandomForest는 Macro F1이 가장 높고 GradientBoosting보다 편차가 작아 채택
- Test 1회 0.955(기준선 68.2%)는 88명 표본이라 참고값으로만 사용

검증 설계: 데이터 누수 방지

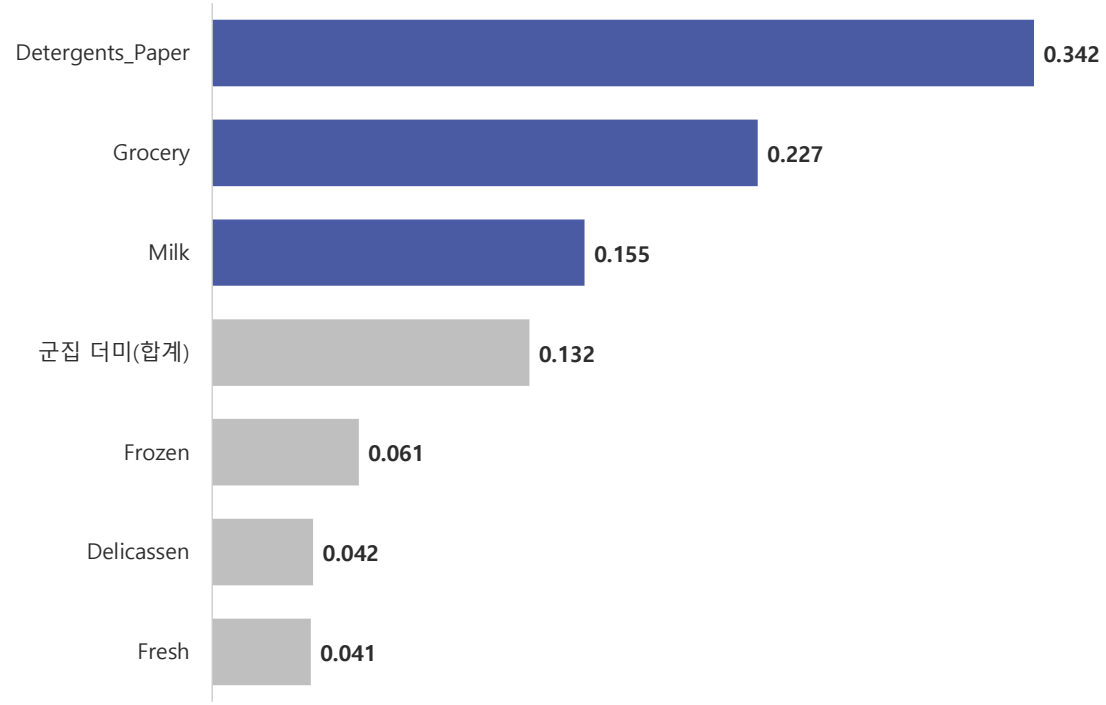
1. **원본부터 Train/Test 분할**
   전처리 전에 먼저 분할: Train 352명 · Test 88명
2. **Train 내부 5-fold 교차검증**
   StratifiedKFold(5)로 채널 비율을 유지한 채 분할
3. **폴드마다 전처리 새로 fit**
   Yeo-Johnson·표준화·PCA·군집화를 학습 폴드에만 fit, 검증 폴드엔 적용만
4. **교차검증 Macro F1로 모델 선택**
   LogisticRegression·SVM·RandomForest에 class_weight='balanced' 적용(소수 채널 Retail 보정)
5. **Test는 마지막 1회만 평가**
   Test 결과는 모델 선택에 쓰지 않음

04

변수 중요도

Retail 품목 3개가 중요도의 72%를 차지해, Horeca는 "Retail 품목을 적게 구매해서" 구분된다

RandomForest 변수 중요도



해석

- Detergents_Paper · Grocery · Milk 합계 **0.724 (72%)**
- 모델은 Horeca를 "신선식품을 많이 구매해서 " 가 아니라 **" Retail 품목을 적게 구매해서 "** 구분
- Fresh는 0.041로 최하위: 두 채널 모두 신선식품을 구매해서 판별력이 약함.
- 군집 더미(합계 0.132)는 보조 신호이고, 핵심은 원본 구매액

시사점

- Retail 품목 구매가 적은데 Retail로 등록된 고객은 **실제 구매 행동이 Horeca형**일 가능성.

05

오분류
고객 분석

1. 오분류 고객 4명
2. 신뢰도 기준 2가지 유형

05

오분류 고객 4명

88명
Test 고객

4명
오분류 (4.5%)

2 : 2
Horeca→Retail : Retail→Horeca

고객 idx	실제 → 예측	예측 신뢰도	페르소나	오분류 유형
181	Horeca → Retail	0.52 (저신뢰)	C2 대량 신선·냉동형	규모 이상치형
342	Horeca → Retail	0.61 (저신뢰)	C1 중간 규모형	카테고리 이탈형
223	Retail → Horeca	0.98 (고신뢰)	C0 소량 신선식품형	라벨-행동 불일치형
11	Retail → Horeca	0.997 (고신뢰)	C0 소량 신선식품형	라벨-행동 불일치형

- 고신뢰 오분류 2명은 C0에서 나왔고, 11은 구성도 Horeca형이며 223은 Retail 품목이 적어 Horeca로 예측된 고객이다.

05

신뢰도 기준 2가지 유형

예측 신뢰도



저신뢰 오분류

0.98 미만

고객 181, 342 · 관측 0.52~0.61

의미
모델도 확신하지 못하는 경계 고객

대응 방향
성급한 결론 대신 **검증을 우선**

고신뢰 오분류

0.98 이상

고객 223, 11 · 관측 0.98~0.997

의미
모델은 확신하는데 등록 채널과 다른 고객

대응 방향
등록 채널(Retail)과 실제 구매 행동(Horeca형)이 어긋남 → **행동 기준으로 대응**

06

마케팅 전략

1 전략 원칙

2 유형별 핵심 액션 (유형 A1·A2·B·C)

06

마케팅 전략 원칙

등록 채널은 그대로 두고, 우리 서비스를 고객의 실제 구매 행동에 맞춘다.

1

등록 채널은 유지

채널은 고객의 업종 정체성이므로 "채널을 바꾸라"고 요구할 대상이 아님

2

서비스를 행동에 맞춤

카탈로그·배송·영업 등 우리 쪽 제안을 실제 구매 패턴 기준으로 조정

3

신뢰도 = 액션 강도

예측 신뢰도가 높을수록 즉시 실행, 낮을수록 검증부터

예측 신뢰도에 따른 액션 강도

신뢰도 낮음 (0.98 미만)

검증 우선

발주 이력을 먼저 확인하고, 성급한 결론 대신 소규모 시범 제안

신뢰도 높음 (0.98 이상)

실행

내부 서비스 기준을 실제 행동에 맞춰 전환 · 단, 품목 구성이 혼합이면 구매 이력 확인을 먼저

06

유형 A-1. 라벨-행동 불일치형

진단

고객 11 · C0 소량 신선식품 중심형

고객 11 · 실제 Retail → **예측 Horeca** **Horeca 99.7% · Retail 0.3%**

품목별 구매액 vs 채널별 중앙값

변수	고객 11	Horeca 중앙값	Retail 중앙값	판정
Det_Paper	549	386	5,615	Horeca
Grocery	4,523	2,684	12,390	Horeca
Milk	1,124	2,157	7,812	Horeca
Fresh	13,146	9,582	5,994	Horeca

판정: 두 중앙값의 로그 중간점 기준 · Det_Paper·Grocery·Milk = 중요도 상위 3개(72%)

- 중요도 상위 3개 품목 구매액이 **모두 Horeca 수준**: Det_Paper 549는 Horeca 중앙값(386)에 가깝다
- Fresh 13,146으로 Horeca 중앙값(9,582)보다 많아 **규모와 구성 모두 Horeca형**

실행 액션

1. **서비스 전환**
   신선 식자재 카탈로그 우선 노출, Horeca 전문 영업사원 배정
2. **정기배송 제안**
   Fresh 중심 품목을 주/월 단위 정기배송으로 묶어 구매 주기 고정
3. **교차판매**
   신선 정기배송에 세제·종이류를 묶은 번들 할인 제공
4. **구매 반응 모니터링**
   제안 후 Fresh 재구매 여부와 주기를 추적해 서비스 유지 여부 판단

신뢰도 0.997 · 구성도 Horeca형 → 즉시 실행

06

유형 A-2. 라벨-행동 불일치형

진단

고객 223 · C0 소량 신선식품 중심형

고객 223 · 실제 Retail → **예측 Horeca** **Horeca 98% · Retail 2%**

품목별 구매액 vs 채널별 중앙값

변수	고객 223	Horeca 중앙값	Retail 중앙값	판정
Det_Paper	788	386	5,615	Horeca
Grocery	5,265	2,684	12,390	Horeca
Milk	2,527	2,157	7,812	Horeca
Frozen	5,612	2,058	1,081	Horeca
Fresh	2,790	9,582	5,994	Retail

판정: 두 중앙값의 로그 중간점 기준 · Det_Paper·Grocery·Milk = 중요도 상위 3개(72%)

- C0(소량 신선식품 중심형) 소속이지만 Fresh **2,790**은 Retail 중앙값(5,994)보다도 낮고, 비중 15%로 C0 평균(50%)과 거리가 멀다
- Horeca 예측은 신선식품이 아니라 **Retail 품목을 적게 사서** 나온 결과: 구매 이력 확인이 먼저

실행 액션

1. **구매 이력 확인**
   최근 발주에서 Frozen 중심·Retail 품목 소량 패턴이 유지되는지 먼저 확인
2. **냉동 정기배송 제안**
   Frozen 31% 비중을 살려 냉동 품목 정기배송과 대량 단가 제시
3. **Retail 서비스 병행**
   Grocery 비중이 커 기존 Retail 카탈로그는 유지하고 냉동 카탈로그를 추가 노출
4. **구매 반응 모니터링**
   냉동 정기배송 제안 후 재구매 여부로 서비스 확대 판단

신뢰도 0.98이지만 혼합 구성 → 구매 이력 확인 후 실행

06

유형 B. 카테고리 이탈형

진단

고객 342 · C1 중간 규모 식료품·유제품·세제/종이류 중심형

고객 342 · 실제 Horeca → **예측 Retail** **Horeca 39% · Retail 61%**

품목별 구매액 vs 채널별 중앙값

변수	고객 342	Horeca 중앙값	Retail 중앙값	판정
Det_Paper	4,595	386	5,615	Retail
Grocery	5,923	2,684	12,390	Retail
Milk	5,758	2,157	7,812	Retail
Fresh	255	9,582	5,994	Retail

판정: 두 중앙값의 로그 중간점 기준 · Det_Paper·Grocery·Milk = 중요도 상위 3개(72%)

- 상위 3개 품목이 **모두 Retail 쪽**: Det_Paper 4,595는 Horeca 중앙값(386)의 약 12배
- 다만 Grocery 5,923은 판정 경계(5,767)와 거의 같은 **경계 고객**: 신뢰도 0.61

실행 액션

1 **발주 이력 검증**
신뢰도가 낮으므로 최근 주문 이력으로 일시적 변동인지 구조적 이탈인지 판단

2 **이탈 원인 파악**
영업사원 컨택으로 가격·신선도·납품 주기 중 경쟁 열위 요인 확인

3 **재유입 오퍼**
원인에 맞춰 Fresh 첫 구매 체험·할인가, 소량·고빈도 납품 조건 제시

신뢰도 0.61 → 검증 후 제안

06

유형 C. 규모 이상치형

진단

고객 181 · C2 대량 신선·냉동·즉석/가공식품 구매형

고객 181 · 실제 Horeca → **예측 Retail** **Horeca 48% · Retail 52%**

품목별 구매액 vs 채널별 중앙값

변수	고객 181	Horeca 중앙값	Retail 중앙값	판정
Det_Paper	4,948	386	5,615	Retail
Grocery	18,148	2,684	12,390	Retail
Milk	29,627	2,157	7,812	Retail
Fresh	112,151	9,582	5,994	Horeca

판정: 두 중앙값의 로그 중간점 기준 · Det_Paper·Grocery·Milk = 중요도 상위 3개(72%)

- 규모가 커서 상위 3개 품목이 **모두 Retail 쪽**: Milk 29,627은 Retail 중앙값의 약 3.8배
- Fresh 112,151(전체 최대값)은 Horeca 쪽이라 **신호가 엇갈림**: 신뢰도 0.52

실행 액션

1 **Key Account 관리**
전담 계정관리자 배정, 개별 계약가·납품 조건(SLA) 협상, 대량구매 할인

2 **리텐션 최우선**
이탈 시 매출 손실이 크므로 이탈 방지를 최우선 목표로 둔다

3 **분석 플래그**
향후 채널예측에서 초고액 고객은 별도 그룹으로 플래그 처리

신뢰도 0.52 → 별도 관리

07

한계 및 결론

1 한계 및 향후 과제

2 결론

07

한계 및 향후 과제

전략 근거가 오분류 4명뿐이라, 표본 확대와 파일럿 검증이 다음 과제다

1 표본 한계

한계
전략 근거가 Test 88명 중 오분류 4명뿐

향후 과제
cross_val_predict로 440명 전원의 검증 예측을 만들어 오분류 표본 확대한다.

2 군집 안정성

한계
k=4 실루엣 0.281로 약함, 시드에 따라 경계 고객 소속이 바뀜 (ARI 0.84~0.91)

향후 과제
경계 고객 해석 시 주의, 소속 변동 고객은 별도 표시

3 데이터 한계

한계
누적 구매액만 있어 시점에 대해 알 수 없고, 연도·화폐 단위도 불명확

향후 과제
현재 시장에 바로 적용하기 어려워, 최신 거래 데이터로 재검증 필요

4 실행 검증

한계
제안 전략은 데이터 기반 가설

향후 과제
실제 적용 전 파일럿(A/B 테스트)으로 효과 검증

07

결론

01 구매 패턴만으로 고객 유형과 채널이 설명된다

4개 페르소나 중 C0·C2는 Horeca 90% 이상, C3는 Retail 87%. 예상 위험군은 채널이 섞인 C1이었지만, 실제 오분류 4명 중 C1은 1명이고 고신뢰 오분류 2명은 모두 Horeca 98%인 C0에서 나왔다.

02 채널 정보 없이도 약 92% 구분된다

교차검증 정확도 약 92%(RandomForest). Retail 품목 3개가 변수 중요도의 72%이다.

03 오분류 고객은 신뢰도에 따라 다르게 대응한다

등록 채널은 유지하고 서비스를 실제 행동에 맞춤. 신뢰도 0.98 이상은 즉시 실행(혼합 구성은 구매 이력 확인 먼저), 미만은 검증부터 해야한다.

예측과 등록 채널이 어긋나는 고객은 실제 구매 행동에 맞춘 제안이 필요한 마케팅 대상이며, 채널예측 모델은 이들을 정기적으로 찾아내는 도구가 된다.

감사합니다

김정우, 안재원